

Week 7 assignment

一、Explain the concept of score matching and describe how it is used in score-based (diffusion) generative models.

(一)、score matching 的概念

在 generative model 中，其中一個目標是想找到數據的分布情形，也就是去學習機率密度函數(PDF)，假設

$$pdf = p(x; \theta) = \frac{1}{z(\theta)} \exp(q(x; \theta)),$$

其中 $z(\theta)$ 是用來讓 $\int_{-\infty}^{\infty} p(x) dx = 1$ 的常數，但在實際應用中 $z(\theta)$ 可能因為維度高或是函數的複雜性導致非常難以計算，因此為了瞭解數據的分布狀況又避免去計算 $z(\theta)$ ，就關注在 $q(x; \theta)$ 函數上，先對 $p(x; \theta)$ 取 \log 會得到 $\log p(x; \theta) = q(x; \theta) - \log z(\theta)$ ，因為 $z(\theta)$ 只與 θ 有關，所以對 x 做梯度計算後就能將 $z(\theta)$ 項去掉，也得到所謂的 score function:

$$S(x) = \nabla_x \log q(x; \theta)$$

(二)、score matching 的原理

如果我們知道完整的機率密度函數 $p(x)$ 的話，可以使用 Explicit score matching(ESM):

$$L_{ESM}(\theta) = \mathbb{E}_{x \sim p(x)} \|S(x; \theta) - \nabla_x \log p(x)\|^2,$$

但在實際情況基本上不會知道 $p(x)$ ，這時候就出現兩種解決辦法

1. Implicit Score Matching(ISM)搭配 Sliced Score Matching(SSM):

$$L_{ISM}(\theta) = \mathbb{E}_{x \sim p(x)} [\|S(x; \theta)\|^2 + 2\nabla_x \cdot S(x; \theta)],$$

透過計算我們能知道

$$\begin{aligned} & \mathbb{E}_{x \sim p(x)} \|S(x; \theta) - \nabla_x \log p(x)\|^2 \\ &= \mathbb{E}_{x \sim p(x)} [\|S(x; \theta)\|^2 + 2\nabla_x \cdot S(x; \theta)] + \mathbb{E}_{x \sim p(x)} [\|\nabla_x \log p(x)\|^2], \end{aligned}$$

而 $\mathbb{E}_{x \sim p(x)} [\|\nabla_x \log p(x)\|^2]$ 這一項只與 $p(x)$ 有關，與 θ 無關，所以針對 L_{ESM} 與 L_{ISM} 的 θ 進行最小化是等價的。

但另一個問題則是 $L_{ISM}(\theta)$ 中的 $\nabla_x \cdot S(x; \theta)$ 可以改寫成

$\text{tr}(\nabla_x S(x; \theta))$ ，但這一項也是非常難以計算的，而經過計算證明後會發現 $\text{tr}(\nabla_x S(x; \theta)) = \mathbb{E}_{v \sim p(v)} [v^T \nabla_x (v^T S(x; \theta))]$ ，所以 $L_{ISM}(\theta)$ 就可以被改寫成

$$\begin{aligned} & L_{SSM}(\theta) \\ &= \mathbb{E}_{x \sim p(x)} [\|S(x; \theta)\|^2] + \mathbb{E}_{x \sim p(x)} \mathbb{E}_{v \sim p(v)} [2v^T \nabla_x (v^T S(x; \theta))], \end{aligned}$$

上述的 $L_{SSM}(\theta)$ 在最小化的計算上就只需要通過 **forward** 和 **back propagation** 就能達成，因此在計算上就會方便很多，而因為 **score function** 可以知道數據分布的梯度值，所以透過最小化 $L_{SSM}(\theta)$ 訓練出的 $S(x)$ ，就可以用來引導一個數據跑到機率最大的預測值。

2. Denoising Score Matching (DSM):

假設我們有一個原始的數據分布 $p_0(x_0)$ ，透過已知的雜訊去擾亂原始數據，得到帶噪的數據分布 $p_\sigma(x|x_0)$ ，經過計算可以得到

L_{ESM} of noisy score function:

$L_{ESM}(\theta)$ for noisy score function

$$= \mathbb{E}_{x \sim p_\sigma(x)} \|S_\sigma(x; \theta) - \nabla_x \log p_\sigma(x)\|^2$$

$$= \mathbb{E}_{x_0 \sim p_0(x_0)} \mathbb{E}_{x|x_0 \sim p(x|x_0)} [\|S_\sigma(x) - \nabla_x \log p(x|x_0)\|^2] + C$$

$$= L_{DSM}(\theta)$$

所以為了找到 **noisy score function**，最小化 $L_{DSM}(\theta)$ 、 $L_{ESM}(\theta)$ 與 $L_{ISM}(\theta)$ 是相同的，而如果我們的加噪方式是利用 **gaussian noise**

來達成，那 $\nabla_x p_\sigma(x|x_0) = -\frac{1}{\sigma^2} \epsilon_\sigma$ ，而 $L_{DSM}(\theta)$ 就可以寫成

$$\mathbb{E}_{x \sim p(x)} \mathbb{E}_{v \sim p(v)} \left\| S_\sigma(x; \theta) + \frac{x - x_0}{\sigma^2} \right\|^2,$$

這樣的寫法就會讓 $L_{DSM}(\theta)$ 的計算方便很多，只要透過 **forward** 和 **back propagation** 就能達成，所以就能輕鬆的訓練去噪模型，而之後給任何的噪音數據，都能夠通過去噪模型來預測出原始的乾淨數據。

二、Unanswered questions

score-based generative models 是透過 **Score Function** 來引導生成預測數據。但目前方法類似於梯度上升，每一步都採用預設的、保守的小步長，有沒有也找到或訓練出曲率資訊，來增加預測效率。