

1. Show that the sliced score matching (SSM) loss can also be written as

$$L_{SSM} = \mathbb{E}_{x \sim p(x)} \mathbb{E}_{v \sim p(v)} [\|v^T S(x; \theta)\|^2 + 2v^T \nabla_x (v^T S(x; \theta))].$$

from week 7-2 notes we have

$$L_{SSM}(\theta) = \mathbb{E}_{x \sim p(x)} \|S(x; \theta)\|^2 + \mathbb{E}_{x \sim p(x)} \mathbb{E}_{v \sim p(v)} [2v^T \nabla_x (v^T S(x; \theta))]$$

$$\text{We want: } L_{SSM}(\theta) = \mathbb{E}_{x \sim p(x)} \mathbb{E}_{v \sim p(v)} [\|v^T S(x; \theta)\|^2 + 2v^T \nabla_x (v^T S(x; \theta))]$$

$$\Rightarrow \text{we only need to prove that } \mathbb{E}_{v \sim p(v)} \|v^T S(x; \theta)\|^2 = \|S(x; \theta)\|^2$$

fixed x , then $S(x; \theta) = (s_1, s_2, \dots, s_d)$ with s_1, \dots, s_d are constants

$\because v \in \mathbb{R}^d \Rightarrow v^T S(x; \theta)$ is a scalar

$$\begin{aligned} \Rightarrow \|v^T S(x; \theta)\|^2 &= (v^T S(x; \theta))^2 = (v^T S(x; \theta))(v^T S(x; \theta))^T \\ &= v^T (S(x; \theta) S(x; \theta)^T) v \end{aligned}$$

$$\begin{aligned} \text{By Hutchinson's trace estimator, } \mathbb{E}_{v \sim p(v)} \|v^T S(x; \theta)\|^2 &= \mathbb{E} [v^T (S(x; \theta) S(x; \theta)^T) v] \\ &= \text{tr}(S(x; \theta) S(x; \theta)^T) \\ &= s_1^2 + s_2^2 + \dots + s_d^2 \\ &= \|S(x; \theta)\|^2 \end{aligned}$$

$$\therefore \text{we prove that } \mathbb{E}_{v \sim p(v)} \|v^T S(x; \theta)\|^2 = \|S(x; \theta)\|^2$$

then we can derive that

$$L_{SSM}(\theta) = \mathbb{E}_{x \sim p(x)} \mathbb{E}_{v \sim p(v)} [\|v^T S(x; \theta)\|^2 + 2v^T \nabla_x (v^T S(x; \theta))] \quad \#$$

2. Briefly explain SDE

SDE 是在一個標準的微分方程基礎上，增加了一個隨機項，SDE 的通式如下：

$$dX_t = f(x, t)dt + g(t)dW_t$$

而這個方程式在說明數據 X_t 在一段極小的時間 dt 內的微小變化 dX_t ，可以由

Drift Term 和 Diffusion Term 組成：

- Drift Term 為 $f(x, t)dt$ ：若方程只有 Drift Term，也就是 $dX_t = f(x, t)dt$ ，那就是一般常見的 ODE， $f(x, t)$ 代表的則是在不同時間的數據變化速率，相較後面提到的 Diffusion Term，給這個數據比較明確的變化趨勢。

- Diffusion Term 為 $g(t)dW_t$ ：這一項則是建立在 ODE 的基礎上，再額外加入一些隨機噪音， $g(t)$ 指在時間 t 時，隨機噪音要放大或縮小多少， dW_t 是 Wiener Process(or Brownian Motion) 的變量，也就是再 dt 時間內要加入的隨機噪音。

而在 Diffusion Model 中，加噪的過程就可以被視為一種 SDE，讓這些數據隨著時間持續且平滑的加入噪音，而解噪的過程(由起始噪音生成的過程)剛好也是一種 SDE，且解噪的 SDE 可以寫成

$$dX_t = [f(x, t) - g(t)^2 \nabla_x \log p_t(x)]dt + g(t)d\overline{W}_t$$

其中 $f(x, t)$ 和 $g(t)$ 是從加噪的過程就知道的， \overline{W}_t 則是反向的 Wiener Process 同樣是隨機的，所以唯一要求的 $\nabla_x \log p_t(x)$ ，剛好就是之前提到的 score function，所以只要搭配 SDE(連續平滑的特性)與 score function 就能有效訓練出能隨時調整輸出品質或輸出速度的模型，而不像 DDPM，若加噪的過程是 1000 次，生成圖片也需要花 1000 次的離散訓練限制。

3. Unanswered Questions

不同的加噪過程，會訓練出不同的解噪模型，那在不同的實務應用中，該如何選擇出適當的加噪過程？